

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
FACULDADE DE CIÊNCIAS ECONÔMICAS
DEPARTAMENTO DE ECONOMIA E RELAÇÕES INTERNACIONAIS

JOÃO RAMOS JUNGBLUT

OTIMIZAÇÃO DE PORTFÓLIO: SELECIONANDO ATIVOS
FINANCEIROS COM USO DE APRENDIZADO DE MÁQUINA NÃO
SUPERVISIONADO MINIMIZANDO INFORMAÇÃO MÚTUA

Porto Alegre

2023

JOÃO RAMOS JUNGBLUT

**OTIMIZAÇÃO DE PORTFÓLIO: SELECIONANDO ATIVOS
FINANCEIROS COM USO DE APRENDIZADO DE MÁQUINA NÃO
SUPERVISIONADO MINIMIZANDO INFORMAÇÃO MÚTUA**

Projeto de pesquisa submetido ao Curso de Graduação em Ciências Econômicas da Faculdade de Ciências Econômicas da UFRGS, como requisito parcial para aprovação na Disciplina Técnicas de Pesquisa e Projeto do Trabalho de Diplomação (ECO02274).

Orientador: Prof. Dr. Fernando Augusto Boeira Sabino da Silva

Porto Alegre

2023

Conteúdo

1	Introdução	2
1.1	Questão a investigar	2
1.2	Objetivos e hipóteses	3
1.2.1	Objetivos	3
1.2.2	Hipóteses	3
1.3	Justificativa da importância do estudo	3
2	Revisão de Literatura	5
3	Metodologia	12
4	Esquema Provisório	14
5	Cronograma de execução	16
	Bibliografia	17

1 Introdução

A seleção de ativos para compor um portfólio de investimentos é um processo desafiador e que envolve diversas variáveis. A fim de otimizar esse processo, têm sido utilizadas técnicas de aprendizado de máquina, em particular, algoritmos de clustering, que permitem agrupar ativos com características semelhantes e selecionar aqueles que oferecem o melhor desempenho em relação aos demais. No entanto, ainda há muitas questões em aberto quanto ao uso dessas técnicas na seleção de ativos, tais como o impacto do uso de diferentes algoritmos de aprendizado de máquina não supervisionado na performance da seleção de ativos e na eficácia da otimização do portfólio, bem como suas limitações e implicações práticas. Diante disso, este trabalho tem como objetivo investigar como a aplicação de técnicas de aprendizado de máquina não supervisionado pode ser utilizada para selecionar ativos e, posteriormente, fazer a construção de portfólio de investimentos.

1.1 Questão a investigar

O objetivo deste trabalho é investigar como as técnicas de aprendizado de máquina não supervisionado podem ser aplicadas para otimizar a seleção de ativos em uma carteira de investimentos. A questão a ser explorada é como os algoritmos de clustering podem ser utilizados para agrupar ativos com menor grau de associação e selecionar aqueles com características de risco e retorno mais singulares para construção de um portfólio diversificado. O trabalho avaliará o impacto do uso desses algoritmos na seleção de ativos financeiros e na eficácia da otimização do portfólio, também serão discutidas as implicações práticas e possíveis limitações do uso de tais técnicas. O estudo examinará como as diferentes abordagens de construção de portfólio podem influenciar o desempenho do modelo e como os resultados podem ser avaliados por medidas diversas. O objetivo final é fornecer uma análise comparativa dos modelos de otimização de portfólio e suas implicações para os investidores. Diferentes métricas de avaliação serão abordadas para medir o desempenho dos modelos de aprendizado de máquina e de alocação de portfólios, além de considerar as restrições e desafios envolvidos na aplicação destas ferramentas em finanças.

1.2 Objetivos e hipóteses

1.2.1 Objetivos

Este trabalho tem como objetivo principal investigar a utilização de técnicas de aprendizado de máquina não supervisionado para selecionar ativos financeiros para construção portfólio de investimentos. Especificamente, pretende-se avaliar como algoritmos de clustering podem ser utilizados para agrupar ativos com menor grau de associação e, posteriormente, selecionar aqueles com características mais singulares para construção de uma carteira bem diversificada. Além disso, este trabalho também busca não só comparar diferentes modelos de portfólio e suas implicações para os investidores, mas também avaliar com diferentes métricas de performance se os resultados obtidos pelos portfólios possuem uma relação risco e retorno superior ao índice de mercado.

1.2.2 Hipóteses

A hipótese principal deste trabalho é que a utilização de técnicas de aprendizado de máquina não supervisionado pode otimizar a seleção de ativos em um portfólio de investimentos, levando a uma construção de portfólio mais diversificada e com melhores características de risco e retorno. Além disso, espera-se que a utilização de diferentes algoritmos de clustering possa impactar na eficácia da seleção de ativos e na performance das carteiras ótimas. Também se acredita que diferentes abordagens de construção de portfólio possam influenciar o desempenho do modelo e que as medidas selecionadas possam afetar os resultados. Por fim, considera-se que o estudo das implicações práticas e possíveis limitações do uso de técnicas de aprendizado de máquina não supervisionado na seleção de ativos possa fornecer informações valiosas para os profissionais da área.

1.3 Justificativa da importância do estudo

A seleção de ativos financeiros é uma das etapas mais críticas na construção de carteiras de investimentos, pois dela depende, em grande parte, a obtenção de retornos positivos e a minimização dos riscos envolvidos. Se a escolha de ativos for inadequada, podem ocorrer perdas financeiras significativas. Nesse contexto, a aplicação de algoritmos de clustering tem se mostrado uma abordagem promissora para aprimorar a seleção de ativos em um portfólio. Isso permite uma análise mais abrangente e criteriosa das características dos

ativos, contribuindo para uma tomada de decisão mais embasada. No entanto, ainda há muitas incertezas sobre o uso dessas técnicas, e é necessário um estudo mais aprofundado para avaliar sua eficácia e limitações. Portanto, a investigação proposta neste trabalho é de grande importância para compreender como as técnicas de aprendizado de máquina podem ser aplicadas à seleção de ativos financeiros e como elas podem impactar na performance de um portfólio. Isso pode levar a decisões de investimento mais precisas e, conseqüentemente, melhorar o retorno financeiro dos investidores. Ademais, os resultados obtidos poderão fornecer informações relevantes para os profissionais da área e contribuir para o avanço do conhecimento em finanças.

2 Revisão de Literatura

A compreensão dos mercados financeiros apresenta um grande desafio devido à sua dinâmica altamente complexa. Em geral, qualquer estudo econômico deve levar em consideração algum grau elevado de incerteza, o qual associa-se às mudanças de comportamento que os agentes realizam com base no nível de informação que possuem. [Fama \(1970\)](#) aborda essa questão ao definir a hipótese dos mercados eficientes, afirmando que sobre determinadas circunstâncias, os preços refletem toda informação disponível. A solução proposta aponta para um equilíbrio de mercado determinado pelos retornos esperados como uma função do seu risco. As suposições levantadas respeitam a ideia de um "jogo justo", no qual a probabilidade de ganhar ou perder é a mesma, resultando em dois modelos diferentes. O primeiro assume que o movimento dos preços é um martingale, ou seja, o retorno esperado é igual a zero. O segundo sugere que as séries de preços seguem um passeio aleatório, com retornos independentes em cada instante de tempo e distribuição conhecida.

Considerando a hipótese dos mercados eficientes como razoavelmente válida, na prática é impossível, ou pelo menos extremamente difícil, prever os preços dos ativos financeiros. Contudo, isso não significa necessariamente que um gestor de portfólios não possa obter - de forma ativa - uma relação risco-retorno superior à composição total do mercado. Um trabalho recente de [de Prado \(2020\)](#) destaca que *"enquanto investidores, nós não temos controle (legítimo) sobre os preços, e a decisão essencial que nós podemos e devemos fazer é definir o tamanho da aposta adequadamente"*¹. Portanto, é importante focar não só em estudos que apresentem soluções para a alocação ótima de uma carteira de investimentos, mas também em trabalhos que mostrem métodos para a seleção de ativos que irão compor essa carteira.

Em seu estudo sobre a transmissão de informações por canais de comunicação, [Kelly \(1956\)](#) apresenta um exemplo prático que aborda o problema mencionado anteriormente. O exemplo envolve um apostador que utiliza informações recebidas para lucrar com suas apostas. Os resultados demonstram que, a cada rodada, o jogador maximiza o logaritmo do capital esperado, pois em uma sequência de apostas repetidas, onde se aplica a lei dos grandes números, a fortuna do apostador depende apenas da porcentagem definida do

¹"As investors, we have no (legitimate) control over prices, and the key decision we can and must make is to size bets properly.", p. 69.

capital a ser apostado.

[Markowitz \(1952\)](#) propõe outra abordagem para analisar as preferências dos agentes. Ele argumenta que os investidores não devem considerar somente o retorno esperado de cada ativo, mas também o risco associado a cada um e a correlação que possuem entre si. Portanto, eles devem diversificar seu capital para encontrar os pesos do portfólio ótimo, que maximiza o retorno restrito à mínima variância. Esse portfólio ótimo é encontrado na fronteira eficiente.

Em sua análise, [Latane \(1959\)](#) propõe a utilização de critérios adicionais para estratégias de alocação de ativos financeiros. Ele reconhece que embora Markowitz tenha desenvolvido um método para selecionar portfólios eficientes, ainda é necessário fornecer maneiras objetivas de ajustar o indicador de aversão ao risco. Seu processo é dividido em três partes, com um objetivo principal, um objetivo secundário e um critério de definição de estratégias. Baseado em Bernoulli, a conclusão da análise sugere que um gestor de portfólios maximiza a riqueza no longo prazo ao: *(i)* maximizar a expectativa matemática, *(ii)* maximizar a utilidade esperada e *(iii)* escolher a carteira de investimentos com maior probabilidade de sucesso.

As divergências entre os modelos apresentados geraram diferentes posicionamentos entre o meio acadêmico e a comunidade financeira. De acordo com [Samuelson \(1963\)](#), o uso de uma função logarítmica de utilidade pelos agentes econômicos violaria a suposição de comportamento racional, pois para um determinado nível de aversão ao risco, as escolhas realizadas seriam incoerentes, resultando na chamada "Falácia de Samuelson" sobre a lei dos grandes números. No entanto, [Thorp \(1975\)](#) rebate essa argumentação ao destacar a distinção entre os diferentes tipos de teorias de utilidade² e afirmar que o uso da utilidade logarítmica é prescritivo, ou seja, orienta a tomada de decisão de grupos e instituições que visam maximizar o retorno. Além disso, ressalta que ao maximizar a utilidade logarítmica, portfólios com maior probabilidade de perdas são eliminados, o que reduz parcialmente o risco.

Recentemente, [Carr and Cherubini \(2022\)](#) publicaram um estudo que busca solucionar o debate em torno do uso da utilidade logarítmica na maximização da riqueza. Eles propõem uma nova definição de equilíbrio de mercado que não faz referência a um

²Thorp compara três tipos de teoria da utilidade: Descritiva (quando os dados observados são ajustados matematicamente), Preditiva (que explica os dados observados) e Prescritiva (usada para guiar o comportamento afim de alcançar determinado objetivo).

indivíduo específico, apenas às leis relativas ao retorno excedido de uma carteira de investimentos. Utilizando leis de potência para maximizar a riqueza, os autores afirmam que as regras de composição não podem ser arbitrárias e que a dinâmica do evento não depende do comportamento do investidor, porém da própria natureza do mercado. O modelo econômico desenvolvido indica que a especulação de preços inclui um processo que governa a dinâmica do tempo e que, se o tempo de negociação é estocástico, a média dos retornos deve levar em consideração essa aleatoriedade. Foram introduzidos dois modelos dinâmicos, sendo que no primeiro caso, é utilizada a distribuição de Variância Gamma (VG), e é encontrada a mesma função de riqueza proposta por Samuelson, porém sem a inclusão de uma função de utilidade. Já no segundo caso, é usado um modelo de Distribuição Normal Gaussiana Inversa (NIG), e é encontrada uma função quadrática de riqueza semelhante à abordagem de Markowitz. Em ambos os casos, o impacto do crescimento ótimo do portfólio é isomórfico ao aumento da aversão ao risco, e o parâmetro que desempenha o papel do índice de aversão ao risco é a variância do stochastic clock ³.

Até o momento, discutimos sobre métodos de tomada de decisão para investimentos. No entanto, é igualmente importante avaliar se as escolhas realizadas foram as melhores possíveis. Nesse sentido, [Sharpe \(1963\)](#) propõe novos meios para avaliar carteiras de investimentos. O modelo de Markowitz, por exemplo, indica que para dois portfólios com mesma variância, deve-se selecionar aquele com maior retorno esperado. Analogamente, para dois portfólios com retorno esperado equivalente, deve-se escolher aquele com menor variância. A melhor combinação de ativos é aquela que se encontra na fronteira eficiente, sendo o ponto tangente à função objetivo. Esta métrica denominada de índice de Sharpe, além de servir como medida de avaliação, sugere a porcentagem que os investidores devem alocar em renda variável e em ativos livres de risco.

Existem outras métricas de performance disponíveis na literatura. Por exemplo, o alfa de Jensen indica o retorno excedente de um portfólio em relação ao retorno esperado. O alfa mede a habilidade do gestor em gerar ganhos independentemente das movimentações do mercado. Um alfa positivo indica que o gestor agregou valor, enquanto um alfa negativo indica que os resultados ficaram abaixo do esperado, conforme [Jensen \(1969\)](#). O índice de Treynor ajusta o retorno excedente relativo ao risco (medido pelo beta) assumido pelo gestor. Essa medida representa o risco do portfólio que não pode ser eliminado

³A ideia desse processo é conectar a volatilidade dos retornos ao fluxo de informação do mercado, o qual nem sempre é uniforme no tempo e sequer diretamente observável. Ver [Geman \(2009\)](#).

por diversificação, ou seja, o risco sistêmico. Quanto maior o índice de Treynor, maior o retorno gerado em relação à quantidade de risco sistêmico assumida, como explica [Treynor \(1961\)](#).

Ambas as medidas estão alinhadas com o famoso modelo de precificação de ativos CAPM, proposto por [Sharpe \(1964\)](#). Esse modelo assume que os investidores são racionais e avessos ao risco, exigindo uma compensação para assumi-lo. Dessa forma, o retorno esperado pode ser explicado pela taxa livre de risco, pelo prêmio de risco⁴ e por um componente idiossincrático.

Ao longo dos anos, a quantificação do risco se tornou uma parte essencial para a tomada de decisão em investimentos, especialmente em meio as quebras das bolsas de valores. Grandes instituições desenvolveram métodos para medir o risco, incluindo o Value at Risk (VaR), criado pelo J.P. Morgan em meados da década de 1980, ver [Longerstaey and Spencer \(1996\)](#). Embora o VaR possua três dos quatro axiomas necessários para ser considerado uma medida de risco coerente, ele não é sub-aditivo. Logo, quando tratamos de problemas de otimização de portfólios, em que múltiplos ativos estão sendo considerados, não obrigatoriamente pode acontecer de o VaR da carteira ser maior que a soma do VaR individual de cada ativo, o que leva a uma falsa conclusão de que diversificar não faz sentido. Por tais motivos, [Rockafellar et al. \(2000\)](#) propõe que as otimizações sejam feitas restrito ao mínimo Conditional Value at Risk (CVaR), também conhecido por Expected Shortfall (ES), que é uma medida de risco de cauda que estabelece a perda esperada quando a queda ultrapassa o limite do VaR para determinado nível de confiança.

Outrossim, para criar portfólios que sejam menos sensíveis a mudanças nas condições de mercado e a precisão das suposições subjacentes, [Fabozzi et al. \(2007\)](#) sugere a incorporação de uma variedade de cenários e riscos potenciais no processo de construção do portfólio, em vez de depender de um único conjunto de suposições ou dados históricos. Essa abordagem ajuda a reduzir o impacto de eventos extremos de mercado, como quebras ou bolhas, no desempenho da carteira de investimento. Para implementar essa otimização robusta de portfólio, Fabozzi apresenta o uso de uma combinação de técnicas, incluindo programação estocástica, permitindo que os investidores incorporem uma variedade de cenários e riscos potenciais de mercado no processo de construção do portfólio. O objetivo final é criar portfólios resilientes a uma variedade de riscos e incertezas potenciais,

⁴Essa relação é dada por: $\beta \times (R_m - R_f)$.

presentes nos mercados financeiros. Também possibilitando a geração de retornos fortes no longo prazo para os investidores.

Avanços significativos têm sido feitos no uso de modelos econométricos para estimar a volatilidade de ativos financeiros. Uma abordagem importante é o modelo ARCH, introduzido por [Engle \(1982\)](#) e nas finanças por [Bollerslev et al. \(1992\)](#), que supõe que a variação dos retornos de um ativo financeiro muda com o tempo e depende de seus próprios retornos passados. A utilidade do modelo ARCH em finanças é amplamente reconhecida, e tem sido aplicado em diversas áreas, como precificação de ativos, otimização de portfólio e gerenciamento de risco.

Em outro trabalho, [Bollerslev et al. \(1988\)](#) propõem uma versão do modelo CAPM que leva em consideração covariâncias que variam no tempo entre os retornos de diferentes ativos. Ao contrário do CAPM tradicional, que assume que as covariâncias entre os retornos dos ativos são constantes ao longo do tempo, o modelo proposto por Bollerslev, Engle e Wooldridge incorpora a ideia de que essas covariâncias mudam no tempo. Isso é particularmente importante porque a suposição de covariâncias constantes pode levar a estimativas imprecisas dos retornos esperados e do risco. Para explicar a variação da volatilidade, é utilizado um modelo multivariado GARCH, que permite a estimativa de matrizes de covariância móveis no tempo entre os retornos de diferentes ativos. A aplicação desse modelo em um conjunto de dados de retornos de ações revelou que as covariâncias móveis no tempo têm efeitos significativos nas estimativas de retornos e riscos esperados.

Ademais, o uso de cópulas como uma forma de modelar a estrutura de dependência entre riscos de crédito em uma carteira foi proposto por [Li \(2000\)](#). No entanto, esse modelo foi criticado por assumir que a estrutura de dependência entre os riscos de crédito era estável ao longo do tempo, o que se mostrou uma grande falha durante a crise financeira, quando as correlações entre diferentes ativos repentinamente se tornaram altamente correlacionadas. [Engle \(2002\)](#) demonstrou que analisar a correlação dinâmica é mais adequado, uma vez que o retorno de ativos financeiros está positivamente correlacionado com a volatilidade do mercado.

Outros autores, como [Cherubini et al. \(2004\)](#) e [McNeil et al. \(2015\)](#), também apresentaram importantes trabalhos com o uso de cópulas em finanças. [Christoffersen \(1998\)](#) propôs o uso de cópulas para estimar medidas de risco por meio da modelagem da de-

pendência entre diferentes ativos financeiros. Ao modelar a estrutura de dependência com cópulas, podemos estimar a distribuição conjunta de diferentes ativos financeiros e calcular medidas como VaR e ES que levam em consideração o comportamento conjunto dos ativos. Christoffersen mostrou que usar cópulas pode levar a estimativas de risco mais precisas em comparação com métodos tradicionais que assumem independência entre ativos ou usam estruturas de dependência simplistas, como correlações.

Novos métodos para a seleção de ativos continuaram a ser desenvolvidos a partir do referencial teórico. [De Luca et al. \(2010\)](#) criou uma heurística para a seleção de ativos que combina aprendizado de máquina e cópulas. Três etapas foram realizadas no artigo: (i) aplicação de modelos univariados AR-GARCH, (ii) seleção dos ativos usando técnicas de mineração de dados, algoritmo random forest ⁵, para filtrar os ativos com menor dependência caudal inferior e (iii) cópulas para estimar os coeficientes de dependência caudal. O uso de random forest ajuda a identificar as variáveis mais importantes, enquanto o uso de cópulas ajuda a modelar a estrutura de dependência entre elas para construir um portfólio eficiente. A aplicação dos procedimentos se mostrou eficiente para reduzir o drawdown ⁶ durante a crise de 2008.

Um conjunto de técnicas foi proposto para lidar com a incerteza nos dados de entrada por [De Prado \(2016\)](#). Um dos principais desafios da otimização do portfólio é que os pesos ideais do portfólio obtidos usando dados históricos podem não ter um bom desempenho quando aplicados a dados futuros fora da amostra. Isso é conhecido como overfitting. Para resolver esse problema, Lopez de Prado inseriu um novo método chamado algoritmo Hierarchical Risk Parity (HRP), baseado em técnicas de aprendizado de máquina. O algoritmo HRP apresenta diversas vantagens em relação aos métodos convencionais de otimização de portfólio. Em particular, é menos suscetível a flutuações nos dados de entrada e capaz de se ajustar a novas condições de mercado com maior flexibilidade. Ademais, tende a gerar carteiras mais amplamente diversificadas, o que pode diminuir o risco de perdas significativas.

Por fim, no livro "Machine Learning for Asset Managers", [de Prado \(2020\)](#) explora diversas técnicas que fazem uso de algoritmos de aprendizado de máquina supervisionado e não supervisionado para lidar com problemas como instabilidade numérica, eliminação

⁵Esse algoritmo constrói várias árvores de decisão usando subconjuntos de variáveis e observações aleatórias do conjunto de dados e agrega as previsões de cada árvore de decisão para obter uma previsão final.

⁶medida de risco que mede a perda máxima de um investimento a partir do seu valor máximo anterior.

de ruídos decorrentes de efeitos substitutivos e multicolinearidade, além de melhorar a precisão de previsões e identificar a importância de cada variável. O livro também fornece orientações práticas para profissionais financeiros obterem resultados mais confiáveis em seu trabalho, baseando-se em teorias econômicas.

3 Metodologia

A otimização de portfólio é uma técnica amplamente utilizada no mercado financeiro para maximizar a relação risco-retorno de um conjunto de ativos financeiros. No entanto, a diversificação excessiva pode levar a uma alocação ineficiente dos ativos, resultando em baixo retorno. Nesse contexto, o uso de modelos de aprendizado de máquina não supervisionado pode ajudar a reduzir a diversificação excessiva e melhorar a eficiência da alocação dos ativos.

Neste trabalho, propomos uma metodologia para a construção de uma carteira ótima utilizando diferentes modelos de aprendizado de máquina não supervisionado para selecionar os ativos com menor associação (medida pela Informação Mútua) e modelos de otimização, como Mínima Variância e CVaR, para a construção da carteira ótima. Além disso, comparamos os resultados obtidos pelos diferentes modelos de otimização em termos de relação risco-retorno.

A metodologia proposta para a construção de uma carteira ótima utilizando diferentes modelos de aprendizado de máquina não supervisionado e modelos de otimização pode ser dividida nas seguintes etapas:

Passo 1 (Coleta dos dados) *Escolha dos dados históricos dos ativos financeiros, como preços de fechamento, em um período de tempo determinado.*

Passo 2 (Pré-processamento) *Remoção de dados faltantes e outliers, cálculo dos retornos, normalização dos dados e ajuste para a frequência desejada (diário, semanal, mensal).*

Passo 3 (Previsão) *Utilização de modelos de séries temporais ARMA-GARCH univariado para prever os retornos dos ativos financeiros selecionados.*

Passo 4 (Análise de características) *Cálculo da matriz de associação entre os retornos dos ativos financeiros por meio da métrica de Informação Mútua.*

Passo 5 (Aplicação dos modelos de aprendizado de máquina) *Uso de diferentes algoritmos de aprendizado não supervisionado, como k-means, hierarchical clustering, DBSCAN, PCA e Sparse Subspace Clustering (SSC) para selecionar os ativos financeiros com menor associação.*

Passo 6 (Seleção dos ativos) *Escolha dos ativos financeiros selecionados pelo modelo de aprendizado não supervisionado para compor a carteira.*

Passo 7 (Cálculo da distribuição multivariada) *Uso de cópulas para modelar a dependência entre os ativos selecionados.*

Passo 8 (Construção do portfólio) *Aplicação de diferentes modelos de otimização, como Média-Variância e CVaR, para construir a carteira ótima com os ativos selecionados.*

Passo 9 (Comparação dos resultados) *Avaliação dos resultados obtidos pelos diferentes modelos de otimização em termos de relação risco-retorno, retorno esperado, volatilidade, entre outras métricas relevantes.*

Passo 10 (Teste de Robustez) *Avaliação da robustez das carteiras ótimas por meio do modelo de fatores Fama-French.*

4 Esquema Provisório

Título Provisório: *"OTIMIZAÇÃO DE PORTFÓLIO: SELECIONANDO ATIVOS FINANCEIROS COM USO DE APRENDIZADO DE MÁQUINA NÃO SUPERVISIÃO MINIMIZANDO INFORMAÇÃO MÚTUA"*.

Classificação de acordo com JEL:

C38 – Classification Methods • Cluster Analysis • Principal Components • Factor Models

C41 – Duration Analysis • Optimal Timing Strategies

G11 – Portfolio Choice • Investment Decisions

G17 – Financial Forecasting and Simulation

1. INTRODUÇÃO

1.1. CONTEXTUALIZAÇÃO

1.2. OBJETIVOS

1.3. HIPÓTESE

1.4. JUSTIFICATIVA

1.5. ORGANIZAÇÃO DO TRABALHO

2. REVISÃO BIBLIOGRÁFICA

1. OTIMIZAÇÃO DE PORTFÓLIO

2. GERENCIAMENTO DE RISCO

3. MODELOS PREDITIVOS

4. APRENDIZADO DE MÁQUINA

5. SELEÇÃO DOS ATIVOS

3. ESPECIFICAÇÃO DOS MODELOS

1. DESCRIÇÃO DOS MODELOS DE APRENDIZADO DE MÁQUINA

2. DESCRIÇÃO DOS MODELOS DE OTIMIZAÇÃO DE PORTFÓLIO

3. DESCRIÇÃO DAS MÉTRICAS DE PERFORMANCE E AVALIAÇÃO

4. METODOLOGIA

1. DESCRIÇÃO DA ESTRATÉGIA
2. FONTE DE DADOS E JUSTIFICAÇÃO
3. MÉTRICAS DE PERFORMANCE
4. ANÁLISE DE ROBUSTEZ

5. RESULTADOS EMPÍRICOS

1. APRESENTAÇÃO DOS RESULTADOS OBTIDOS
2. DISCUSSÃO EM RELAÇÃO A HIPÓTESE INICIAL
3. ANÁLISE DAS VANTAGENS E PREJUÍZOS
4. COMPARAÇÃO ENTRE AS CARTEIRAS COM O ÍNDICE DE REFERÊNCIA

6. CONCLUSÃO

1. RECAPITULAÇÃO DOS PRINCIPAIS RESULTADOS
2. LIMITAÇÕES DO ESTUDO E SUGESTÕES FUTURAS
3. IMPORTÂNCIA E APLICABILIDADE

7. REFERÊNCIAS

8. APÊNDICE

5 Cronograma de execução

ETAPA	MAIO	JUNHO	JULHO	AGOSTO	SETEMBRO
1. Especificação dos modelos	X				
2. Procedimentos metodológicos	X	X			
3. Validação dos resultados		X			
4. Conclusões relativo a hipótese inicial			X		
5. Contextualização do tema			X		
6. Considerações finais e revisão				X	
7. Redação final				X	
8. Defesa					X

Bibliografia

- Tim Bollerslev, Robert F Engle, and Jeffrey M Wooldridge. A capital asset pricing model with time-varying covariances. *Journal of political Economy*, 96(1):116–131, 1988.
- Tim Bollerslev, Ray Y Chou, and Kenneth F Kroner. Arch modeling in finance: A review of the theory and empirical evidence. *Journal of econometrics*, 52(1-2):5–59, 1992.
- Peter Carr and Umberto Cherubini. Generalized compounding and growth optimal portfolios reconciling kelly and samuelson. *The Journal of Derivatives*, 30(2):74–93, 2022.
- Umberto Cherubini, Elisa Luciano, and Walter Vecchiato. *Copula methods in finance*. John Wiley & Sons, 2004.
- Peter F Christoffersen. Evaluating interval forecasts. *International economic review*, pages 841–862, 1998.
- Giovanni De Luca, Giorgia Riveccio, and Paola Zuccolotto. Combining random forest and copula functions: a heuristic approach for selecting assets from a financial crisis perspective. *Intelligent Systems in Accounting, Finance & Management*, 17(2):91–109, 2010.
- Marcos Lopez De Prado. Building diversified portfolios that outperform out of sample. *The Journal of Portfolio Management*, 42(4):59–69, 2016.
- Marcos M López de Prado. *Machine learning for asset managers*. Cambridge University Press, 2020.
- Robert Engle. Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3):339–350, 2002.
- Robert F Engle. Autoregressive conditional heteroscedasticity with estimates of the variance of united kingdom inflation. *Econometrica: Journal of the econometric society*, pages 987–1007, 1982.
- Frank J Fabozzi, Sergio M Focardi, Petter N Kolm, and Dessislava A Pachamanova. *Robust portfolio optimization and management*. John Wiley & Sons, 2007.

- Eugene F Fama. Efficient capital markets: A review of theory and empirical work. *The journal of Finance*, 25(2):383–417, 1970.
- Hélyette Geman. Stochastic clock and financial markets. In *Handbook of Numerical Analysis*, volume 15, pages 649–663. Elsevier, 2009.
- Michael C Jensen. Risk, the pricing of capital assets, and the evaluation of investment portfolios. *The Journal of business*, 42(2):167–247, 1969.
- John L Kelly. A new interpretation of information rate. *the bell system technical journal*, 35(4):917–926, 1956.
- Henry Allen Latane. Criteria for choice among risky ventures. *Journal of Political Economy*, 67(2):144–155, 1959.
- David X Li. On default correlation: A copula function approach. *The Journal of Fixed Income*, 9(4):43–54, 2000.
- Jacques Longestaey and Martin Spencer. Riskmetricstm—technical document. *Morgan Guaranty Trust Company of New York: New York*, 51:54, 1996.
- Harry Markowitz. Portfolio selection. *Journal of Finance*, 7(1):77–91, 1952.
- Alexander J McNeil, Rüdiger Frey, and Paul Embrechts. *Quantitative risk management: concepts, techniques and tools-revised edition*. Princeton university press, 2015.
- R Tyrrell Rockafellar, Stanislav Uryasev, et al. Optimization of conditional value-at-risk. *Journal of risk*, 2:21–42, 2000.
- P. Samuelson. Risk and uncertainty: A fallacy of large numbers. *Scientia*, 57(98):108, 1963.
- William F Sharpe. A simplified model for portfolio analysis. *Management science*, 9(2): 277–293, 1963.
- William F Sharpe. Capital asset prices: A theory of market equilibrium under conditions of risk. *The journal of finance*, 19(3):425–442, 1964.
- Edward O Thorp. Portfolio choice and the kelly criterion. In *Stochastic optimization models in finance*, pages 599–619. Elsevier, 1975.

Jack L Treynor. Market value, time, and risk. *Time, and Risk (August 8, 1961)*, 1961.